

Mantenimiento predictivo basado en sensores IoT: limpieza y análisis exploratorio de datos

Reporte ejecutivo

Industrias Metalmecánicas del Norte

Alberto Josué Hernández Armas

Carné: 201903553

Universidad de San Carlos de Guatemala

Seminario de Sistemas 2

Tarea del segundo parcial

Guatemala, junio de 2026

Resumen

La empresa instaló una red de sensores en doce máquinas críticas con el fin de anticipar fallos y reducir paradas no planificadas. El conjunto de datos original, compuesto por cincuenta lecturas, presentaba problemas frecuentes en entornos industriales: códigos centinela, valores fuera de rango físico, atípicos extremos, errores de formato y ruido en variables categóricas. Este informe documenta la depuración del archivo y el análisis exploratorio posterior. Tras el proceso, el conjunto quedó sin valores faltantes y conservó las cincuenta observaciones. El análisis muestra una correlación muy alta entre las cuatro variables de sensor (coeficientes de 0.96 a 0.99) y perfiles de operación claramente distintos entre máquinas. Estos resultados orientan la estrategia de mantenimiento hacia el seguimiento de desviaciones respecto a la línea base de cada equipo.

1. Introducción y descripción del problema

Industrias Metalmecánicas del Norte implementó una red de sensores de Internet de las cosas (IoT) en doce máquinas críticas de su planta. El objetivo de negocio consiste en identificar patrones que permitan predecir fallos antes de que ocurran, de modo que el mantenimiento deje de ser correctivo y pase a ser planificado. Anticipar una falla reduce el tiempo de parada, evita daños mayores en los equipos y mejora la continuidad de la producción.

El archivo de trabajo contiene cincuenta lecturas registradas entre el 1 y el 2 de octubre de 2025, con intervalos aproximados de veinticinco minutos. Cada registro incluye cuatro variables numéricas de sensor (temperatura en grados Celsius, presión en psi, vibración en mm/s y potencia en kW) y varios campos categóricos: identificador de máquina, técnico responsable, modo de inspección, estado operativo y lote de producción. Como suele ocurrir con datos provenientes de sistemas de adquisición automática, el archivo presentaba múltiples problemas de calidad que impedían un análisis confiable y que debían resolverse antes de cualquier interpretación.

Este reporte presenta, en primer lugar, el proceso de limpieza y transformación del conjunto de datos y, en segundo lugar, el análisis exploratorio sobre el archivo depurado. El trabajo se realizó en Python con las librerías pandas para la manipulación de datos y matplotlib para las visualizaciones (Hunter, 2007; McKinney, 2010).

2. Metodología

La depuración siguió un orden deliberado para evitar que los valores absurdos distorsionaran los estadísticos posteriores. Primero se estandarizó la estructura (nombres de columnas y tipos de dato), luego se normalizaron las categorías, después se validaron los rangos físicos y se trataron los valores atípicos, y por último se imputó la información faltante. La imputación de variables numéricas se realizó con la mediana de cada máquina, medida robusta frente a valores extremos y coherente con el hecho de que cada equipo mantiene un perfil de operación estable. El análisis exploratorio aplicó estadística descriptiva y técnicas gráficas para examinar distribuciones, atípicos y relaciones entre variables (Tukey, 1977).

3. Limpieza de datos

Se identificaron y resolvieron doce problemas de calidad. La Tabla 1 resume cada uno junto con el tratamiento aplicado y el número de registros afectados. Conviene aclarar que los pasos 8, 9 y 10 operan de

manera encadenada sobre el mismo conjunto de lecturas inválidas: primero se detectan los valores fuera de rango, luego los atípicos estadísticos y, finalmente, se imputan todos los huecos resultantes.

N.	Problema detectado	Tratamiento aplicado	Reg.
1	Encabezados inconsistentes (time stamp, inspectedby)	Renombrado a formato snake_case homogéneo	2 col.
2	Errores de año en fecha_hora (2035 y 2045)	Corrección al año base 2025 y parseo a datetime	2
3	Marca de exportación constante con minutos imposibles	Eliminación de la columna por metadato redundante	col.
4	Código de máquina mal escrito (M04D)	Corrección a M04 y normalización de mayúsculas	2
5	Ruido textual en técnico responsable (zzzzzzzz)	Conversión a faltante para imputación posterior	1
6	Separadores mixtos en lote (LOTx001, LOT/001)	Unificación al formato LOT-000	4
7	Identificadores faltantes (máquina y técnico)	Imputación con el mapa unívoco máquina a técnico	5
8	Valores fuera de rango físico y centinelas (999, negativos)	Conversión a faltante según rango operativo	16
9	Atípicos extremos por IQR (vibración 15.8, potencia 0.0001)	Conversión a faltante con criterio 1.5 IQR	2
10	Lecturas de sensor faltantes tras la validación	Imputación por mediana de cada máquina	19
11	Categorías residuales faltantes (modo, lote)	Categoría predominante y etiqueta SIN_REGISTRO	2
12	Verificación de duplicados semánticos	No se hallaron; no se eliminó ningún registro	0

Tabla 1. Problemas de calidad detectados y soluciones aplicadas durante la limpieza del conjunto de datos.




Figura 1. Cantidad de valores problemáticos por variable en el archivo crudo frente a los faltantes del conjunto depurado, que se reducen a cero.

Las cuatro variables de sensor concentraban la mayor cantidad de problemas, con la temperatura como la más afectada. Los campos categóricos también presentaban ruido, aunque en menor proporción. La Figura 3 ilustra el efecto del tratamiento de atípicos: el panel izquierdo, en escala simétrica logarítmica, evidencia valores absurdos como una vibración cercana a diez millones de mm/s y registros negativos imposibles, mientras que el panel derecho muestra el conjunto ya depurado y sin valores extremos.

Figura 3. Diagramas de caja antes y después del tratamiento de atípicos




Figura 3. Diagramas de caja de las variables de sensor antes (datos crudos, escala simétrica logarítmica) y después del tratamiento de valores atípicos.

Tras la depuración, el conjunto conservó las cincuenta observaciones y no quedó ningún valor faltante. Se optó por imputar en lugar de eliminar filas debido al tamaño reducido de la muestra, en la que cada registro aporta información relevante.

4. Análisis exploratorio de datos

4.1 Descripción y medidas de tendencia central

El conjunto depurado abarca cincuenta lecturas de doce máquinas. Por estado operativo, treinta y ocho lecturas corresponden a equipos operativos, nueve a equipos fallados y tres a equipos en mantenimiento. La Tabla 2 presenta las medidas de tendencia central y dispersión de las variables de sensor.

Variable	Media	Mediana	Moda	Desv.	Mín	Q1	Q3	Máy
Temperatura (C)	81.47	82.30	75.80	10.40	64.50	71.22	92.18	96.20
Presión (psi)	39.92	40.35	37.90	5.72	29.80	35.12	45.15	48.10
Vibración (mm/s)	2.46	2.30	2.00	0.70	1.40	1.92	3.08	3.60
Potencia (kW)	14.94	15.65	9.50	3.22	9.50	12.50	18.18	19.40

Tabla 2. Medidas de tendencia central y dispersión de las variables de sensor en el conjunto depurado.

En todas las variables la media y la mediana resultan cercanas, lo que indica distribuciones razonablemente simétricas una vez removidos los valores extremos. La moda más baja en potencia refleja la presencia de máquinas de menor consumo dentro del parque.

4.2 Distribución de las variables

Figura 2. Distribucion de las variables de sensor tras la limpieza




Figura 2. Histogramas de las cuatro variables de sensor con la media y la mediana señaladas.

Las distribuciones presentan varios picos. Este comportamiento multimodal no responde a errores, sino a la coexistencia de doce máquinas con niveles de operación distintos: cada equipo agrupa sus lecturas en torno a su propio valor característico, y la suma de esos grupos genera los picos observados.

4.3 Correlación entre variables




Figura 4. Mapa de correlación de Pearson entre las cuatro variables de sensor.

Las cuatro variables presentan correlaciones positivas muy altas, con coeficientes entre 0.96 y 0.99. Esto significa que tienden a aumentar y disminuir de manera conjunta: cuando una máquina opera con mayor carga, su temperatura, presión, vibración y potencia se elevan simultáneamente. En la práctica, las cuatro señales transmiten información parcialmente redundante, lo que tiene implicaciones directas para el diseño de un modelo predictivo, como se discute en las recomendaciones.

4.4 Perfil de operación por máquina y por estado




Figura 5. Temperatura y potencia promedio de cada una de las doce máquinas.

Cada máquina mantiene un perfil estable y diferenciado. La máquina M08 opera en el extremo más bajo (alrededor de 65 grados y 9.5 kW), mientras que M05 lo hace en el más alto (cerca de 96 grados y 19 kW).

La temperatura y la potencia siguen la misma tendencia entre equipos, lo que confirma la relación observada en la matriz de correlación. Esta heterogeneidad implica que un umbral único para toda la planta sería inadecuado, pues lo normal en una máquina puede ser anómalo en otra.

Figura 6. Estado operativo y firma de vibracion




Figura 6. Distribución de lecturas por estado operativo y vibración promedio asociada a cada estado.

La vibración promedio es algo mayor en los equipos en mantenimiento (2.80 mm/s) y fallados (2.67 mm/s) que en los operativos (2.38 mm/s), y la temperatura sigue un patrón similar. La señal apunta en la dirección esperada, ya que la vibración suele anticipar deterioro mecánico, pero la separación es moderada y el número de lecturas en los estados no operativos es reducido. Por ello conviene tratar este hallazgo como una hipótesis a confirmar con más datos.

5. Conclusiones y recomendaciones

El archivo original estaba considerablemente contaminado: una parte importante de las lecturas de sensor presentaba códigos centinela, valores imposibles o atípicos extremos. Tras la limpieza, el conjunto quedó listo para el análisis sin pérdida de observaciones. El hallazgo principal es la fuerte correlación entre las variables de sensor y la marcada diferencia de comportamiento entre máquinas, lo que define el enfoque más adecuado para el mantenimiento. La asociación entre vibración o temperatura y los estados no operativos existe, aunque es modesta con la ventana de datos disponible.

A partir de estos resultados se proponen las siguientes recomendaciones:

1. Vigilar desviaciones respecto a la línea base de cada equipo. Dado que cada máquina tiene su propio nivel normal de operación, conviene definir rangos de control individuales en lugar de un umbral común para toda la planta.
2. Priorizar la vibración y la temperatura como indicadores tempranos. Ambas se elevan ligeramente en los estados de mantenimiento y falla, son económicas de medir y resultan razonables como primeras señales de alerta.
3. Corregir la captura de datos en el origen. Eliminar los códigos centinela como 999, validar los rangos físicos de cada sensor, exigir un formato único de fecha y de lote, y hacer obligatorio el registro del técnico

responsable.

4. Ampliar la ventana de observación e incorporar variables temporales. Las veintiuna horas registradas resultan insuficientes para un modelo predictivo. Conviene acumular un historial más amplio y construir indicadores de tendencia, como promedios móviles, que capturen la evolución previa a una falla.

5. Usar un modelo parsimonioso. Por la alta redundancia entre señales, uno o dos sensores, o un índice combinado, bastan para describir el estado de la máquina sin agregar información duplicada.

6. Referencias

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95.

McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56-61).

Mobley, R. K. (2002). *An introduction to predictive maintenance* (2.^a ed.). Butterworth-Heinemann.

Organización Internacional de Normalización. (2009). ISO 10816-3: Mechanical vibration. Evaluation of machine vibration by measurements on non-rotating parts. ISO.

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Apéndice A. Código fuente

El procedimiento completo de limpieza y análisis se encuentra documentado y comentado en el archivo `analisis_sensores.py`, disponible también en formato de cuaderno (`analisis_sensores.ipynb`). El flujo carga el archivo crudo, aplica de manera secuencial los tratamientos descritos en la Tabla 1, exporta el conjunto depurado como `sensores_limpios.csv` y genera las figuras incluidas en este reporte. El código puede alojarse en un repositorio para su consulta: [enlace a GitHub o Google Colab].